LAPORAN MATA KULIAH
ANALITIK & VISUALISASI DATA
DATASET GLOBAL *FREELANCERS*

DISUSUN OLEH:

Sabrina Azhmalia Nisa : 2509116051

KELAS B

PROGRAM STUDI SISTEM INFORMASI

FAKULTAS TEKNIK

UNIVERSITAS MULAWARMAN

2026

DAFTAR ISI

DAFTAR ISI ii
DAFTAR GAMBAR iii
DAFTAR TABEL iv
BAB I PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Tujuan 1
BAB II PEMBAHASAN 3
2.1 Tahapan Proses yang Dilakukan 3
2.1.1 Business Understanding 3
2.1.2 Data Understanding 4
2.2 Exploratory Data Analysis (EDA) 15
2.2.1 Comparison/Perbandingan 15
2.2.2 Composition/Komposisi 17
2.2.3 Distribution/Distribusi 18
2.2.4 Relationship/Hubungan 19
BAB III PENUTUP 21
3.1 Kesimpulan 21

DAFTAR GAMBAR

Gambar 2.1.2. 1 Output Dataset.....5
Gambar 2.1.2 2 Output Statistik Deskriptif Data.....6
Gambar 2.1.2 3 Output Cek Tipe Data 7
Gambar 2.1.2 4 Output Incosistent Values (freelancer_ID).....8
Gambar 2.1.2 5 Output Inconsistent Values (name) 9
Gambar 2.1.2 6 Output Inconsistent Values (gender) 9
Gambar 2.1.2 7 Output Inconsistent Values (country).....10
Gambar 2.1.2 8 Output Inconsistent Values (language).....10
Gambar 2.1.2 9 Output Inconsistent Values (primary_skill) 10
Gambar 2.1.2 10 Output Inconsistent Values (hourly_rate (USD)).....11
Gambar 2.1.2 11 Output Inconsistent Values (is_active).....11
Gambar 2.1.2 12 Output Inconsistent Values (client_satisfaction).....12
Gambar 2.1.2 13 Output Missing Values 13
Gambar 2.1.2 14 Output Duplicated Values 13
Gambar 2.1.2 15 Output Outliers.....15
Gambar 2.2.1 1 Output Comparison 16
Gambar 2.2.1 2 Output Composition.....17
Gambar 2.2.1 3 Output Distribution 18
Gambar 2.2.1 4 Output Relationship 19

DAFTAR TABEL

Tabel 2.1.2. 1 Kode Memuat Dataset 5
Tabel 2.1.2. 2 Kode Statistik Deskriptif Dataset 6
Tabel 2.1.2. 3 Kode Cek Tipe Data 6
Tabel 2.1.2. 4 Kode Cek Inconsistent Values (freelancer_ID) 7
Tabel 2.1.2. 5 Kode Cek Inconsistent Values (name) 8
Tabel 2.1.2. 6 Kode Cek Inconsistent Values (gender) 9
Tabel 2.1.2. 7 Kode Cek Inconsistent Values (country) 9
Tabel 2.1.2. 8 Kode Cek Inconsistent Values (language) 10
Tabel 2.1.2. 9 Kode Cek Inconsistent Values 10
Tabel 2.1.2. 10 Kode Cek Inconsistent Values (hourly_rate (USD)) 11
Tabel 2.1.2. 11 Kode Cek Inconsistent Values (is_active) 11
Tabel 2.1.2. 12 Kode Cek Inconsistent Values (client_satisfaction) 12
Tabel 2.1.2. 13 Kode Cek Missing Values 12
Tabel 2.1.2. 14 Kode Cek Duplicated Values 13
Tabel 2.1.2. 15 Kode Cek Outliers 14
Tabel 2.2.1. 1 Kode EDA (Comparison) 15
Tabel 2.2.1. 2 Kode EDA (Composition) 17
Tabel 2.2.1. 3 Kode EDA (Distribution) 18
Tabel 2.2.1. 4 Kode EDA (Relationship) 19

BAB I
PENDAHULUAN

1.1 Latar Belakang

Freelancer adalah pekerjaan yang dilakukan oleh individu ataupun kelompok yang menawarkan sebuah jasa atau keahlian tertentu kepada pelanggan melalui platform digital. Fenomena meningkatnya peminat *freelancer* disebabkan oleh berkembangnya teknologi internet, platform kerja secara daring, serta kebutuhan perusahaan akan tenaga kerja yang fleksibel. Terdapat banyak sekali perusahaan yang memanfaatkan jasa *freelancer* untuk berbagai bidang pekerjaan seperti desain grafis, jasa pemrograman, penulisan konten, pemasaran digital, dan bidang pekerjaan profesional lainnya. Hal tersebut menciptakan sebuah sistem kerja baru yang lebih fleksibel, cepat tanggap, dan tidak terbatas pada suatu lokasi geografis.

Analisis data menjadi salah satu pendekatan yang sangat penting dalam memahami pola kerja tersebut. Semakin berkembangnya sistem kerja *freelancer* di berbagai negara, muncul kebutuhan untuk memahami karakteristik para *freelancer* secara lebih mendalam. Informasi yang dibutuhkan seperti asal negara *freelancer*, tingkat pengalaman kerja, keahlian utama yang dimiliki, tarif pendapatan, serta kepuasan klien terhadap servis yang diberikan membuat data ini menjadi penting untuk dianalisis.

Berdasarkan hal tersebut, dilakukan analisis terhadap dataset "Global *Freelancers*" dengan menggunakan Google Colab. Analisis ini dilakukan untuk mengolah informasi yang ada di dalam dataset agar dapat disajikan secara jelas, sistematis, dan dapat memberikan gambaran detail mengenai kondisi *freelancer* yang terjadi. Dengan demikian, analisis ini diharapkan dapat memperoleh pemahaman yang lebih baik mengenai karakteristik *freelancer* secara global serta faktor yang berkaitan dengan tingkat pendapatan dan pengalaman kerja seorang *freelancer* sehingga informasi tersebut dapat dimanfaatkan untuk memahami pola ekonomi digital yang semakin berkembang.

1.2 Tujuan

Adapun beberapa tujuan analisis ini dilakukan adalah sebagai berikut:

a. Menganalisis bagaimana persebaran *freelancer* berdasarkan negara untuk mengetahi distribusi *freelancer* di berbagai dunia.
b. Mengidentifikasi perbandingan jumlah *freelancer* berdasarkan gender untuk melihat komposisi gender dalam dunia kerja *freelancer.*

c. Menganalisis negara yang memiliki tingkat pendapatan tertinggi untuk melihat potensi pendapatan *freelancer* yang lebih tinggi di suatu negara.
d. Mengidentifikasi hubungan antara pengalaman kerja *freelancer* dengan tingkat pendapatan untuk mengetahui apakah pengalaman kerja memengaruhi terhadap besar tidaknya pendapatan *freelancer.*

BAB II
PEMBAHASAN

2.1 Tahapan Proses yang Dilakukan

Untuk mencapai tujuan analisis ini, adapun tahapan proses yang dilakukan pada dataset, proses tersebut, antara lain:

2.1.1 Business Understanding

a) Business Objective

Di era perkembangan teknologi digital dan internet yang semakin pesat, pola kerja masyarakat pun ikut mengalami perubahan. Perubahan tersebut salah satunya adalah meningkatnya minat masyarakat terhadap pekerjaan *freelancer. Freelancer* adalah seseorang yang bekerja secara independen dengan menjual keahlian atau jasanya kepada klien melalu internet. Meningkatnya minat masyarakat terhadap pekerjaan ini disebabkan karena pekerjaan ini menawarkan fleksibilitas waktu, kebebsan dalam memilih proyek, serta peluang untuk dapat memperoleh penghasilan yang lebih besar dibandingkan pekerjaan konvensional atau pekerjaan biasa yang dilakukan secara tatap muka langsung *(offline).*

Kemajuan teknologi dan keberadaan berbagai platform kerja digital juga menjadi faktor yang mempermudah individu dari berbagai negara untuk menawarkan keahlian atau jasa merkea kepada klien di seluruh dunia tanpa terbatas pada lokasi geografis. Hal inilah yang membuat sistem kerja *freelancer* berkembang secara global yang melibatkan berbagai jenis keahlian atau keahlian seperti desain grafis, pemrograman, dan jenis pekerjaan di bidang profesional lainnya. Oleh karena itu, penting bahwasannya untuk memahami karaktersitik *freelancer* secara global agar mengetahui persebaran tenaga kerja *freelancer* serta faktor-faktor yang memengaruhi tingkat pendapatan mereka.

b) Assess Situation

Dataset ini berisi data mentah tentang *freelancer* fiktif dari berbagai dunia. Data ini memuat informasi seperti identitas *freelancer*, keahlian yang dimiliki, asal negara, pengalaman, penilaian dari pelanggan, dan beberapa informasi lainnya. Dari dataset ini diketahui tidak menggunakan data asli berdasarkan dunia nyata, melainkan data palsu yang dibuat dari *library* palsu dengan menggunakan Python. Sehingga data yang terdapat dalam dataset ini kemungkinan memiliki beberapa keterbatasan seperti format data yang belum konsisten, struktur data yang masih

perlu diperbaiki, serta kemungkinan adanya nilai data yang tidak sepenuhnya menggambarkan kondisi nyata. Namun, data ini dapat membantu untuk melihat bagaimana pola dan perbandingan *freelancer* secara keseluruhan di dunia, di mana informasi ini dapat digunakan untuk memahami kondisi pasar *freelancer* dan faktor apa yang memengaruhi pendapatan *freelancer*.

c) Analytic Goals

Dalam proses analisis dataset ini, adapun tahapan-tahapan yang dilakukan untuk mencapai tujuan analisis dalam mengetahui pola dan karakteristik *freelancer*, tahapan tersebut, antara lain:

1. Mengidentifikasi persebaran *freelancer* di berbagai dunia untuk melihat distribusi pekerjaan *freelancer,* dan negara dengan jumlah *freelancer* tertinggi di dunia.
2. Menganalisis tingkat pendapatan *freelancer* di berbagai negara untuk mengetahui wilayah negara dengan penghasilan tinggi agar dapat melihat apakah terdapat perbedaan kondisi ekonomi *freelancer* antar negara.
3. Menganalisis hubungan antara pengalaman kerja dengan tingkat pendapatan *freelancer* agar mengetahui apakah lama tidaknya pengalaman kerja akan diikuti oleh besar kecilnya pendapatan *freelancer.*
4. Mengetahui faktor-faktor yang memengaruhi kondisi dan performa *freelancer* dalam skala global.

d) Project Plan

Adapun beberapa tahapan pengerjaan yang akan dilakukan untuk mencapai tujuan analisis, antara lain:

1. Memahami, membersihkan, dan menyiapkan data.
2. Menganalisis dan mengidentifikasi pola atau tren yang ada.
3. Membuat grafik untuk menampilkan hasil dari analisis.
4. Memberikan insight atau kesimpulan berdasarkan hasil analisis data.

2.1.2 Data Understanding

Pada tahap ini, dilakukan proses pemahaman terhadap dataset yang digunakan untuk analisis ini. Tahap ini bertujuan untuk mengetahui struktur data, jenis variabel data, dan informasi yang terdapat pada dataset ini. Dataset ini berisi 1000 baris dan 12 kolom, kolom tersebut, yaitu:

a. Freelancer_id, tipe data object.

b. Name, tipe data object.
c. Gender, tipe data object.
d. Age, tipe data float64.
e. Country, tipe data object.
f. Language, tipe data object.
g. Primary_skill, tipe data object.
h. Years_of_experience, tipe data float64.
i. Hourly_rate (USD), tipe data object.
j. Rating, tipe data float64.
k. Is_active, tipe data object.
l. Client_satisfaction, tipe data object.

Untuk mengetahui informasi lebih lanjut dari dataset ini, adapun tahapan yang dilakukan, antara lain:

1) Memuat Dataset

Tabel 2.1.2. 1 Kode Memuat Dataset

```
file = '/content/global_freelancers_raw.csv'
df = pd.read_csv(file)
df
```

Kode pada tabel 2.1.2.1 di atas, digunakan untuk menampilkan seluruh isi data dari dataset "Global Freelancers". Sehingga akan menghasilkan output seperti pada gambar di bawah ini.

	freelancer_ID	name	gender	age	country	language	primary_skill	years_of_experience	hourly_rate (USD)	rating	is_active	client_satisfaction
0	FL250001	Ms. Nicole Kidd	f	52.0	Italy	Italian	Blockchain Development	11.0	100	NaN	0	NaN
1	FL250002	Vanessa Garcia	FEMALE	52.0	Australia	English	Mobile Apps	34.0	USD 100	3.3	1	84%
2	FL250003	Juan Nelson	male	53.0	Germany	German	Graphic Design	31.0	50	0.0	N	71%
3	FL250004	Amanda Spencer	F	38.0	Australia	English	Web Development	4.0	$40	1.5	N	90%
4	FL250005	Lynn Curtis DDS	female	53.0	Germany	German	Web Development	27.0	30	4.8	0	83%
...	...	...	...	...	...	...	...	...	...	...	...	...
995	FL250996	Albert Wilcox	Male	56.0	Turkey	Turkish	DevOps	13.0	100	0.0	no	68%
996	FL250997	Cheryl Norris	f	26.0	Germany	German	Blockchain Development	6.0	USD 40	2.8	N	82
997	FL250998	Kathy Watkins	female	37.0	Japan	Japanese	Data Analysis	15.0	75	NaN	False	94%
998	FL250999	John Obrien	m	46.0	Russia	Russian	Machine Learning	22.0	100	2.8	yes	97
999	FL251000	Dawn Green	Female	36.0	Mexico	Spanish	UI/UX Design	18.0	$20	1.7	1	72

1000 rows × 12 columns

Gambar 2.1.2. 1 Output Dataset

Pada gambar 2.1.2.1 dapat dilihat bahwa dataset berisi berbagai kolom berbeda sebanyak 12 kolom, dengan informasi baris datanya sebanyak 1000. Kolom tersebut berisi nama, jenis kelamin, umur, negara, bahasa, keahlian utama, lama pengalaman

kerja, pendapatan per jam dalam USD, penilaian, status keaktifan, hingga kepuasan pelanggan terhadap *freelancer* tersebut.

2) Statistik Deskriptif

Tabel 2.1.2. 2 Kode Statistik Deskriptif Dataset

```
df.describe(include='all')
```

Kode pada tabel 2.1.2.2 di atas, digunakan untuk mengidentifikasi pada setiap baris data untuk menghitung kelengkapan data, distribusi data, validasi logika, dan standar deviasi atau variabilitas data sehingga menghasilkan sebuah output seperti pada gambar di bawah ini.

	freelancer_ID	name	gender	age	country	language	primary_skill	years_of_experience	hourly_rate (USD)	rating	is_active	client_satisfaction
count	1000	1000	1000	970.000000	1000	1000	1000	949.000000	906	899.000000	911	824
unique	1000	992	10	NaN	21	16	10	NaN	18	NaN	8	81
top	FL251000	Robert Evans	FEMALE	NaN	South Korea	English	DevOps	NaN	40	NaN	1	68%
freq	1	2	115	NaN	68	215	112	NaN	94	NaN	190	23
mean	NaN	NaN	NaN	40.509278	NaN	NaN	NaN	11.340358	NaN	2.512570	NaN	NaN
std	NaN	NaN	NaN	11.942605	NaN	NaN	NaN	9.680610	NaN	1.546599	NaN	NaN
min	NaN	NaN	NaN	20.000000	NaN	NaN	NaN	0.000000	NaN	0.000000	NaN	NaN
25%	NaN	NaN	NaN	31.000000	NaN	NaN	NaN	3.000000	NaN	1.400000	NaN	NaN
50%	NaN	NaN	NaN	41.000000	NaN	NaN	NaN	9.000000	NaN	2.600000	NaN	NaN
75%	NaN	NaN	NaN	51.000000	NaN	NaN	NaN	17.000000	NaN	3.800000	NaN	NaN
max	NaN	NaN	NaN	60.000000	NaN	NaN	NaN	41.000000	NaN	5.000000	NaN	NaN

Gambar 2.1.2 1 Output Statistik Deskriptif Data

Pada gambar 2.1.2.2. dapat terihat bahwa sebagian besar kolom dataset memiliki jumlah data yang lengkap, tetapi masih terdapat beberapa nilai yang hilang, seperti pada kolom age, years_of_experience, horuly_rate, dan client_satisfaction. Dengan demikian, dataset ini, menunjukkan keberagaman kolom karakteristik *freelancer,* meskipun data masih belum lengkap yang memungkinkan adanya ketidakseimbangan distribusi data.

3) Pengecekan Tipe Data

Tabel 2.1.2. 3 Kode Cek Tipe Data

```
df.dtypes
```

Kode pada tabel 2.1.2.3 di atas, digunakan untuk melihat tipe data dari setiap variabel pada dataset, sehingga menghasilkan sebuah output seperti pada gambar di bawah ini.

freelancer_ID	object
name	object
gender	object
age	float64
country	object
language	object
primary_skill	object
years_of_experience	float64
hourly_rate (USD)	object
rating	float64
is_active	object
client_satisfaction	object

dtype: object

Gambar 2.1.2 2 Output Cek Tipe Data

Pada gambar 2.1.2.3 dapat terlihat bahawa setiap kolom variabel memiliki tipe data yang berbeda. Namun, beberapa kolom data masih memiliki tipe data yang belum sesuai dengan isi datanya. Contohnya seperti kolom hourly_rate (USD), dan client_satisfaction yang memiliki tipe data object, di mana seharusnya tipe data pada kolom tersebut bersifat numerik. Hal ini kemungkinan disebabkan karena isi data tersebut memiliki simbol mata uang. Simbol persentase, atau karakter lain yang menyebabkan data tidak dapat langsung dikenali sebagai data numerik. Sedangkan pada kolom lainnya sudah memiliki tipe data yang sesuai.

4) Pengecekan Inconsistent Values

a. Kolom 'freelancer_ID'

Tabel 2.1.2. 4 Kode Cek Inconsistent Values (freelancer_ID)

```
print(df['freelancer_ID'].unique())
```

Kode pada tabel 2.1.2.4 di atas, digunakan untuk mengecek ketidakkonsistenan data pada kolom freelancer_ID, sehingga menghasilkan output seperti pada gambar di bawah ini.

```
['FL250001' 'FL250002' 'FL250003' 'FL250004' 'FL250005' 'FL250006'
 'FL250007' 'FL250008' 'FL250009' 'FL250010' 'FL250011' 'FL250012'
 'FL250013' 'FL250014' 'FL250015' 'FL250016' 'FL250017' 'FL250018'
 'FL250019' 'FL250020' 'FL250021' 'FL250022' 'FL250023' 'FL250024'
 'FL250025' 'FL250026' 'FL250027' 'FL250028' 'FL250029' 'FL250030'
 'FL250031' 'FL250032' 'FL250033' 'FL250034' 'FL250035' 'FL250036'
 'FL250037' 'FL250038' 'FL250039' 'FL250040' 'FL250041' 'FL250042'
 'FL250043' 'FL250044' 'FL250045' 'FL250046' 'FL250047' 'FL250048'
 'FL250049' 'FL250050' 'FL250051' 'FL250052' 'FL250053' 'FL250054'
 'FL250055' 'FL250056' 'FL250057' 'FL250058' 'FL250059' 'FL250060'
 'FL250061' 'FL250062' 'FL250063' 'FL250064' 'FL250065' 'FL250066'
 'FL250067' 'FL250068' 'FL250069' 'FL250070' 'FL250071' 'FL250072'
 'FL250073' 'FL250074' 'FL250075' 'FL250076' 'FL250077' 'FL250078'
 'FL250079' 'FL250080' 'FL250081' 'FL250082' 'FL250083' 'FL250084'
 'FL250085' 'FL250086' 'FL250087' 'FL250088' 'FL250089' 'FL250090'
 'FL250091' 'FL250092' 'FL250093' 'FL250094' 'FL250095' 'FL250096'
 'FL250097' 'FL250098' 'FL250099' 'FL250100' 'FL250101' 'FL250102'
 'FL250103' 'FL250104' 'FL250105' 'FL250106' 'FL250107' 'FL250108'
 'FL250109' 'FL250110' 'FL250111' 'FL250112' 'FL250113' 'FL250114'
 'FL250115' 'FL250116' 'FL250117' 'FL250118' 'FL250119' 'FL250120'
 'FL250121' 'FL250122' 'FL250123' 'FL250124' 'FL250125' 'FL250126'
 'FL250127' 'FL250128' 'FL250129' 'FL250130' 'FL250131' 'FL250132'
 'FL250133' 'FL250134' 'FL250135' 'FL250136' 'FL250137' 'FL250138'
 'FL250139' 'FL250140' 'FL250141' 'FL250142' 'FL250143' 'FL250144'
 'FL250145' 'FL250146' 'FL250147' 'FL250148' 'FL250149' 'FL250150'
 'FL250151' 'FL250152' 'FL250153' 'FL250154' 'FL250155' 'FL250156'
 'FL250157' 'FL250158' 'FL250159' 'FL250160' 'FL250161' 'FL250162'
 'FL250163' 'FL250164' 'FL250165' 'FL250166' 'FL250167' 'FL250168'
 'FL250169' 'FL250170' 'FL250171' 'FL250172' 'FL250173' 'FL250174'
 'FL250175' 'FL250176' 'FL250177' 'FL250178' 'FL250179' 'FL250180'
```

Gambar 2.1.2 3 Output Incosistent Values (freelancer_ID)

Pada gambar 2.1.2.4 dapat terlihat bahwa isi data dari kolom tersebut memiliki format penulisan yang sudah konsisten.

b. Kolom ‘name’

Tabel 2.1.2. 5 Kode Cek Inconsistent Values (name)

```
print(df['name'].unique())
```

Kode pada tabel 2.1.2.5 di atas, digunakan untuk mengecek ketidakkonsistenan data pada kolom name, sehingga menghasilkan output seperti pada gambar di bawah ini.

```
['Ms. Nicole Kidd' 'Vanessa Garcia' 'Juan Nelson' 'Amanda Spencer'
 'Lynn Curtis DDS' 'Lisa Johnson' 'Eric Myers' 'Ricky Graham'
 'Sean Martin' 'Matthew Lloyd' 'Gavin Randall' 'Michelle Curtis'
 'Alice Schneider' 'Phillip Shelton' 'Edward Ferguson' 'Wyatt Stout'
 'Laura Johnson' 'Scott Burns' 'Tyler Aguirre' 'Matthew Lawson'
 'James Cherry' 'Samuel Sanford' 'Cesar Greene' 'Melanie Carter'
 'Jennifer Martin' 'Anna Mccann' 'Marissa Bass' 'Alexis Day' 'Megan Jones'
 'Lori Smith' 'Eric Carpenter' 'Timothy Daniels' 'Robert Nelson'
 'Michael Anderson' 'Jessica Snyder' 'Emily Daniels' 'Jamie Ramirez'
 'Amy Harrison' 'Melinda White' 'James Hernandez' 'Angelica Rogers'
 'Savannah Williams' 'Kaitlyn Schmidt' 'Jason Singh' 'Michelle Ramirez'
 'James Brown' 'Mrs. Samantha Simmons' 'Chase Mason' 'Dominique Ward'
 'Lance Griffin' 'Julie Burgess' 'Don Scott' 'Kyle Atkinson' 'Jimmy Hogan'
 'Jennifer Mcintyre' 'Larry Simpson' 'Laura Price' 'Mark Wright'
 'Samantha Mcdaniel' 'Barbara Foster' 'Courtney Tran' 'Eddie Todd'
 'Christine Johnson' 'Leah Phelps' 'Rebekah Williams' 'Crystal Wilson'
 'Ashley Cordova' 'Vicki Kelly' 'Corey Warren' 'Gina Thompson'
 'Yvonne Berg' 'Thomas Miller' 'Nicholas Burton' 'Jorge Riley'
 'Melvin Harris' 'Jeremy Meyer' 'Timothy Lee' 'Diana Bautista'
 'Leslie Rodriguez' 'Noah Wiggins' 'Bridget Williams' 'Veronica Baker'
 'Andrew Avila' 'Michael Roberson' 'Austin Jenkins' 'Brenda Green'
 'Samuel Pierce' 'Briana Smith' 'Ronald Barrett' 'Matthew Smith'
 'Logan Huang' 'Miranda Hutchinson' 'Paul Richardson' 'Jose Jones'
 'Denise Smith' 'Shelby Mcmahon' 'Bethany Wright' 'David Ortiz'
 'Andrew Lynch' 'Kristopher Meyers' 'Thomas Roth' 'Vicki Brown'
 'Stacy Sutton' 'Kimberly Holland' 'Travis Richardson' 'Jasmin Ho'
 'Mark Paul' 'Jennifer Lewis' 'Elizabeth Lester' 'Kimberly Griffin'
 'Tyler Warner' 'Jane Cox' 'Leah Williams' 'Kevin Wong' 'Robert Andrews'
 'Jessica Torres' 'Teresa Kim' 'Jon Morgan' 'Gloria Chaney'
 'Jesse Campbell' 'Allison Tucker MD' 'Candice Petersen'
 'Christopher Nichols' 'Debra Garcia' 'Andrew Fuentes' 'Jason Carter'
```

Gambar 2.1.2 4 Output Inconsistent Values (name)

Pada gambar 2.1.2.5 dapat terlihat bahwa isi data dari kolom tersebut memiliki format penulisan yang sudah konsisten.

c. Kolom ‘gender’

Tabel 2.1.2. 6 Kode Cek Inconsistent Values (gender)

```
print(df['gender'].unique())
```

Kode pada tabel 2.1.2.6 di atas, digunakan untuk mengecek ketidakkonsistenan data pada kolom gender, sehingga menghasilkan output seperti pada gambar di bawah ini.

```
['f' 'FEMALE' 'male' 'F' 'female' 'm' 'MALE' 'Female' 'M' 'Male']
```

Gambar 2.1.2 5 Output Inconsistent Values (gender)

Pada gambar 2.1.2.6 dapat terlihat bahwa kolom gender memiliki format penulisan yang tidak konsisten, contohnya seperti penulisan kata “female”, “FEMALE”, “f”, “F”, “Female”, di mana semua kata tersebut memiliki arti yang sama. Begitupun dengan format penulisan kata “male”, “MALE”, “m”, “M”, “Male”.

d. Kolom ‘country’

Tabel 2.1.2. 7 Kode Cek Inconsistent Values (country)

```
print(df['country'].unique())
```

Kode pada tabel 2.1.2.7 di atas, digunakan untuk mengecek ketidakkonsistenan data pada kolom country, sehingga menghasilkan output seperti pada gambar di bawah ini.

```
['Italy' 'Australia' 'Germany' 'Netherlands' 'Indonesia' 'United States'
 'Turkey' 'United Kingdom' 'Argentina' 'Japan' 'India' 'Brazil'
 'South Korea' 'Russia' 'Canada' 'France' 'Egypt' 'South Africa' 'China'
 'Mexico' 'Spain']
```

Gambar 2.1.2 6 Output Inconsistent Values (country)

Pada gambar 2.1.2.7 dapat terlihat bahwa isi data dari kolom tersebut memiliki format penulisan yang sudah konsisten.

e. Kolom 'language'

Tabel 2.1.2. 8 Kode Cek Inconsistent Values (language)

```
print(df['language'].unique())
```

Kode pada tabel 2.1.2.8 di atas, digunakan untuk mengecek ketidakkonsistenan data pada kolom language, sehingga menghasilkan output seperti pada gambar di bawah ini.

```
['Italian' 'English' 'German' 'Dutch' 'Indonesian' 'Turkish' 'Spanish'
 'Japanese' 'Hindi' 'Portuguese' 'Korean' 'Russian' 'French' 'Arabic'
 'Afrikaans' 'Mandarin']
```

Gambar 2.1.2 7 Output Inconsistent Values (language)

Pada gambar 2.1.2.8 dapat terlihat bahwa isi data dari kolom tersebut memiliki format penulisan yang sudah konsisten.

f. Kolom 'primary_skill'

Tabel 2.1.2. 9 Kode Cek Inconsistent Values

```
print(df['primary_skill'].unique())
```

Kode pada tabel 2.1.2.9 di atas, digunakan untuk mengecek ketidakkonsistenan data pada kolom primary_skill, sehingga menghasilkan output seperti pada gambar di bawah ini.

```
['Blockchain Development' 'Mobile Apps' 'Graphic Design' 'Web Development'
 'AI' 'Data Analysis' 'UI/UX Design' 'Cybersecurity' 'DevOps'
 'Machine Learning']
```

Gambar 2.1.2 8 Output Inconsistent Values (primary_skill)

Pada gambar 2.1.2.9 dapat terlihat bahwa isi data dari kolom tersebut memiliki format penulisan yang sudah konsisten.

g. Kolom 'hourly_rate (USD)'

Tabel 2.1.2. 10 Kode Cek Inconsistent Values (hourly_rate (USD))

```
print(df['hourly_rate (USD)'].unique())
```

Kode pada tabel 2.1.2.10 di atas, digunakan untuk mengecek ketidakkonsistenan data pada kolom hourly_rate (USD), sehingga menghasilkan output seperti pada gambar di bawah ini.

```
['100' 'USD 100' '50' '$40' '30' '$30' 'USD 75' 'USD 40' nan '$50' '40'
 '75' 'USD 50' 'USD 30' '$20' '20' '$75' '$100' 'USD 20']
```

Gambar 2.1.2 9 Output Inconsistent Values (hourly_rate (USD))

Pada gambar 2.1.2.10 dapat terlihat bahwa format penulisan dalam kolom tersebut masih tidak konsisten, contohnya seperti penulisam angka pendapatan yang memiliki karakter persen, ada yang memakai kata 'USD', dan ada yang memiliki simbol dolar. Sehingga dapat dikatakan bahwa isi data dari kolom tersebut belum konsisten.

h. Kolom 'is_active'

Tabel 2.1.2. 11 Kode Cek Inconsistent Values (is_active)

```
print(df['is_active'].unique())
```

Kode pada tabel 2.1.2.11 di atas, digunakan untuk mengecek ketidakkonsistenan data pada kolom is_active, sehingga menghasilkan output seperti pada gambar di bawah ini.

```
['0' '1' 'N' 'False' 'True' 'yes' 'Y' nan 'no']
```

Gambar 2.1.2 10 Output Inconsistent Values (is_active)

Pada 2.1.2.11 dapat terlihat bahwa masih terdapat data yang tidak konsisten, contohnya seperti terdapat data yang berisi "0", "N", "False", dan "no". Di mana semua kata tersebut memeiliki arti yang sama. Begitupun dengan format penulisan kata "True", "1", "yes", dan "Y".

i. Kolom ‘client_satisfaction’

Tabel 2.1.2. 12 Kode Cek Inconsistent Values (client_satisfaction)

```
print(df['client_satisfaction'].unique())
```

Kode pada tabel 2.1.2.12 di atas, digunakan untuk mengecek ketidakkonsistenan data pada kolom client_satisfaction, sehingga menghasilkan output seperti pada gambar di bawah ini.

```
[nan '84%' '71%' '90%' '83%' '94%' '76%' '77%' '86%' '93%' '70%' '69%'
 '60%' '87%' '75%' '68%' '65%' '100%' '92' '89%' '62%' '82' '81%' '63%'
 '67%' '80%' '74%' '85%' '79%' '72%' '64' '88' '96%' '96' '81' '61%' '97%'
 '64%' '73%' '88%' '72' '92%' '82%' '93' '83' '78' '95%' '80' '87' '66%'
 '78%' '68' '91%' '97' '60' '70' '99%' '76' '86' '95' '74' '100' '73' '67'
 '77' '98%' '71' '85' '91' '94' '84' '90' '62' '65' '75' '63' '61' '66'
 '99' '79' '69' '89']
```

Gambar 2.1.2 11 Output Inconsistent Values (client_satisfaction)

Pada gambar 2.1.2.12 dapat terlihat bahwa masih terdapat beberapa data yang tidak konsisten, contohnya seperti ada data yang memakai simbol tanda persen dan yang tidak. Sehingga dapat dikatakan bahwa isi data dari kolom tersebut belum konsisten.

5) Pengecekan Missing Values

Tabel 2.1.2. 13 Kode Cek Missing Values

```
pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])
```

Kode pada tabel 2.1.2.13 di atas, digunakan untuk mengecek apakah terdapat data yang hilang atau kosong pada setiap kolom data, sehingga menghasilkan output seperti pada gambar di bawah ini.

	Null Ratio in %
freelancer_ID	0.0
name	0.0
gender	0.0
age	3.0
country	0.0
language	0.0
primary_skill	0.0
years_of_experience	5.1
hourly_rate (USD)	9.4
rating	10.1
is_active	8.9
client_satisfaction	17.6

Gambar 2.1.2 12 Output Missing Values

Pada gambar 2.1.2.13 dapat terlihat bahwa sebagian besar kolom data telah memiliki data yang lengkap. Namun, masih terdapat beberapa kolom data yang memiliki data hilang atau kosong, contohnhya seperti kolom age dengan nilai persentase sebanyak 3%, kolom years_of_experience dengna nilai persentase sebanyak 5,1%, kolom hourly_rate (USD) dengan nilai persentase sebanyak 9,4%, kolom rating dengan nilai persentase sebanyak 10,1%, kolom is_active dengan nilai persentase sebanyak 8,9%, dan kolom client_satisfaction dengan nilai persentase sebanyak 17,6%. Dapat dikatakan bahwa kolom yang memiliki kehilangan atau kekosongan data paling besar adalah kolom client_satisfaction, sedangkan kolom dengan nilai kehilangan atau kekosongan data paling rendah adalah kolom age.

6) Pengecekan Duplicated Values

Tabel 2.1.2. 14 Kode Cek Duplicated Values

```
df[df.duplicated()]
```

Kode pada tabel 2.1.2.14 di atas, digunakan untuk mengecek apakah terdapat data duplikat atau *double counting* pada setiap kolom data, sehingga menghasilkan output seperti pada gambar di bawah ini.

freelancer_ID	name	gender	age	country	language	primary_skill	years_of_experience	hourly_rate (USD)	rating	is_active	client_satisfaction

Gambar 2.1.2 13 Output Duplicated Values

Pada gambar 2.1.2.14 dapat terlihat bahwa setiap kolom data tidak memiliki data yang terduplikat atau *double counting.*

7) Pengecekan Outliers

Tabel 2.1.2. 15 Kode Cek Outliers

```
results = []

cols = df.select_dtypes(include=['float64', 'int64'])

for col in cols:
  q1 = df[col].quantile(0.25)
  q3 = df[col].quantile(0.75)
  iqr = q3 - q1
  lower_bound = q1 - 1.5*iqr
  upper_bound = q3 + 1.5*iqr
  outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
  percent_outliers = (len(outliers)/len(df))*100
  results.append({'Kolom': col, 'Persentase Outliers':
percent_outliers})

# Dataframe dari list hasil
results_df = pd.DataFrame(results)
results_df.set_index('Kolom', inplace=True)
results_df = results_df.rename_axis(None,
axis=0).rename_axis('Kolom', axis=1)

# Tampilkan dataframe
display(results_df)
```

Kode pada tabel 2.1.2.15 di atas, digunakan untuk mengecek apakah terdapat outliers atau data anomali pada setiap kolom data, sehingga menghasilkan output seperti pada gambar di bawah ini.

Kolom	Persentase Outliers
age	0.0
years_of_experience	0.9
rating	0.0

Gambar 2.1.2 14 Output Outliers

Pada gambar 2.1.2.15 dapat terlihat bahwa kolom years_of_experience memiliki nilai outliers sebanyak 0,9%. Hal ini menunjukkan nilai outliers yang kecil sehingga tidak terlalu memengaruhi proses analisis. Sedangkan kolom age, dan kolom rating tidak memiliki nilai outliers. Hal ini berarti kedua variabel tersebut relatif normal dan tidak ada nilai ekstrem yang menyimpang dari mayoritas data. Secara keseluruhan, kondisi ini menunjukkan bahwa dataset relatif bersih dari nilai ekstrem.

2.2 Exploratory Data Analysis (EDA)

Setelah melakukan tahapan pengolahan dan analisis data, selanjutnya adalah melakukan visualisasi data untuk melihat hubungan antar variabel secara lebih jelas. Visualisasi ini bertujuan untuk membantu dalam mengidentifikasi pola, tren, serta hubungan yang terdapat dalam dataset sehingga dapat menghasilkan insight yang relevan agar mencapai tujuan analisis. Adapun tahapan visualisasi yang dilakukan, antara lain:

2.2.1 Comparison/Perbandingan

Tabel 2.2.1. 1 Kode EDA (Comparison)

```
penghasilan_freelancer =
df.groupby('primary_skill')['rating'].mean().sort_values(ascending=False)

plt.figure(figsize=(10,6))
sns.barplot(x=penghasilan_freelancer.index,     y=penghasilan_freelancer.values,
palette='Purples', hue=penghasilan_freelancer.index, legend=False)
plt.title('Rating Freelancer Berdasarkan Keahlian Utama')
plt.xlabel('primary_skill')
plt.ylabel('Rating')
plt.xticks(rotation=45)
plt.show()
```

Kode pada tabel 2.2.1.1 di atas, digunakan untuk menganalisis perbandingan antara variabel penilaian pelanggan (rating) dengan variabel keahlian utama seorang *freelancer* (primary_skill). Perbandingan antar variabel ini dibuat untuk melihat apakah terdapat hubungan atau pengaruh antara keahlian utama yang dimiliki oleh *freelancer* dengan tinggi rendahnya penilaian dari pelanggan. Dengan demikian, dapat diketahui apakah terdapat kualitas layanan yang lebih baik di bidang keahlian tertentu. Ketika kode tersebut dijalankan maka akan menghasilkan output seperti pada gambar di bawah ini.

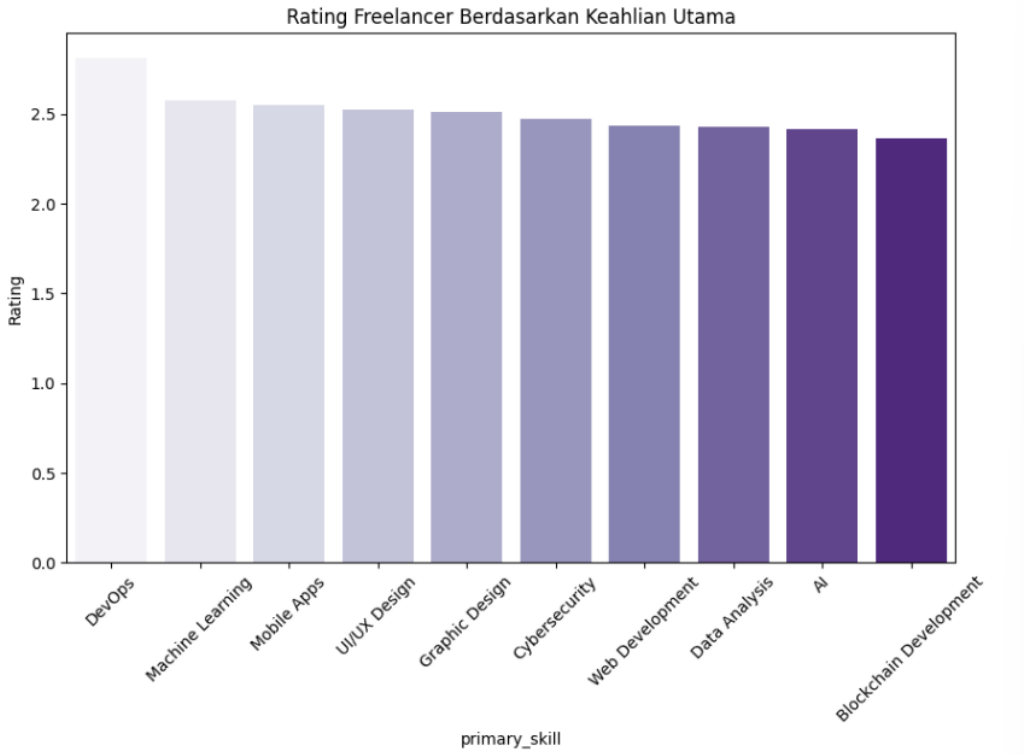

Gambar 2.2.1 1 Output Comparison

Pada gambar 2.2.1.1 dapat terlihat bahwa tingkat rating *freelancer* relatif tidak jauh berbeda antar keahlian. Seluruh kategori keahlian memiliki nilai rata-rata rating sekitar 2,3 hingga 2,8. Hal ini menunjukkan bahwa secara umum tingkat penilaian performa *freelancer* di berbagai keahlian cenderung stabil, walaupun masih terdapat sedikit perbedaan performa antar bidang keahlian. Dari hasil ini juga dapat disimpulkan bahwa jenis keahlian bukan faktor utama yang secara signifikan memengaruhi tinggi rendahnya rating, karena selisih antar nilai relatif kecil.

2.2.2 Composition/Komposisi

Tabel 2.2.1. 2 Kode EDA (Composition)

```
skill_count = df['primary_skill'].value_counts().sort_values(ascending=False)
skill_top3 = skill_count.head(3)

colors = plt.cm.RdPu(np.linspace(0, 1, len(skill_top3)))

plt.figure(figsize=(10, 8))
skill_top3.plot(kind='pie', autopct='%1.1f%%', startangle=140, colors=colors)

plt.title('Proporsi 3 Primary Skill Teratas Berdasarkan Jumlah Freelancer')
plt.ylabel('')
plt.axis('equal')
plt.show()
```

Kode pada tabel 2.2.1.2 di atas, digunakan untuk melihat komposisi dari tiga keahlian teratas apa yang paling banyak diminati oleh *freelancer,* hal ini dilakukan untuk memahami bagaiaman tren pasar tenaga kerja *freelancer* dan mengetahui ketersediaan tenaga kerja di keahlian tertentu. Ketika kode tersebut dijalankan maka akan menghasilkan output seperti pada gambar di bawah ini.

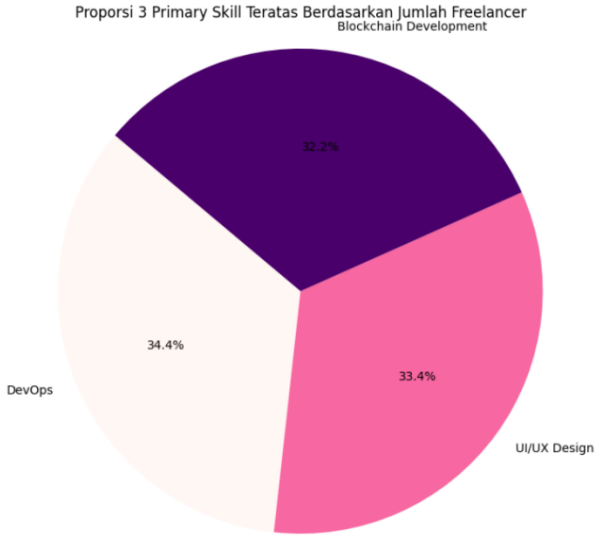

Gambar 2.2.1 2 Output Composition

Pada gambar 2.2.1.2 dapat terlihat bahwa tiga keahlian utama dengan jumlah *freelancer* terbanyak adalah keahlian DevOps dengan nilai persentase sebesar 34,4%, diikuti oleh keahlian UI/UX Design dengan nilai persentase sebesar 33,4%, dab keahlian Blockchain Development dengan nilai sebesar 32,2%. Ketiga proporsi keahlian ini terbilang hampir seimbang, artinya minat atau distribusi *freelancer* pada ketiga bidang tersebut cukup merata dengan memiliki tingkat popularitas tinggi di pasar *freelancer.*

2.2.3 Distribution/Distribusi

Tabel 2.2.1. 3 Kode EDA (Distribution)

```
plt.figure(figsize=(10, 6))
sns.histplot(df['rating'], bins=10, kde=True)
plt.title('Distribusi Rating Freelancer')
plt.xlabel('Rating')
plt.ylabel('Frekuensi')
plt.show()
```

Kode pada tabel 2.2.1.3 di atas, digunakan untuk melihat distribusi penilaian pelanggan *(rating)* kepada performa *freelancer.* Ketika kode tersebut dijalankan maka akan menghasilkan output seperti pada gambar di bawah ini

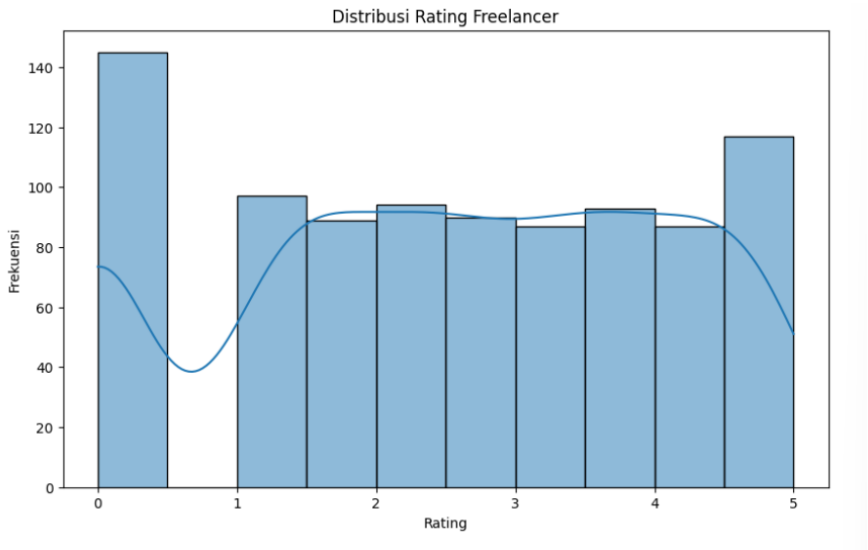

Gambar 2.2.1 3 Output Distribution

Pada gambar 2.2.1.3 dapat terlihat bahwa persebaran distribusi penilaian pelanggan tersebar cukup merata di seluruh rentang nilai 0 hingga 5. Namun, terlihat bahwa frekuensi nilai cukup tinggi juga muncul pada rating rendah yang mendekati nilai 0, serta tetap stabil di rentang menengah hingga tinggi di sekitar nilai 2 hingga nilai 5. Hal ini menunjukkan bahwa kualitas *freelancer* dalam dataset cukup bervariasi, dan dapat menjadi indikasi bahwa tidak semua *freelancer* mampu memberikan kualitas layanan yang konsisten.

2.2.4 Relationship/Hubungan

Tabel 2.2.1. 4 Kode EDA (Relationship)

```
df_cleaned = df.copy()
df_cleaned['hourly_rate (USD)'] = df_cleaned['hourly_rate (USD)'].astype(str).str.replace('USD ', '').str.replace('$', '', regex=False).astype(float)

plt.figure(figsize=(8, 6))
sns.heatmap(
    data=df_cleaned[['rating', 'hourly_rate (USD)']].corr(),
    annot=True,
    cmap='RdPu',
    fmt='.2f'
)
plt.title('Korelasi antara Rating dan Hourly Rate')
plt.show()
```

Kode pada tabel 2.2.1.4 di atas, digunakan untuk melihat apakah terdapat hubungan antara penilaian pelanggan (rating), dan pendapatan per jam *freelancer* (hourly_rate (USD)), hal ini dilakukan unutk memahami apakah kepuasan atau penilaian klien berhubungan dengan besar kecilnya pendapatan *freelancer.* Ketika kode tersebut dijalankan maka akan menghasilkan output seperti pada gambar di bawah ini.

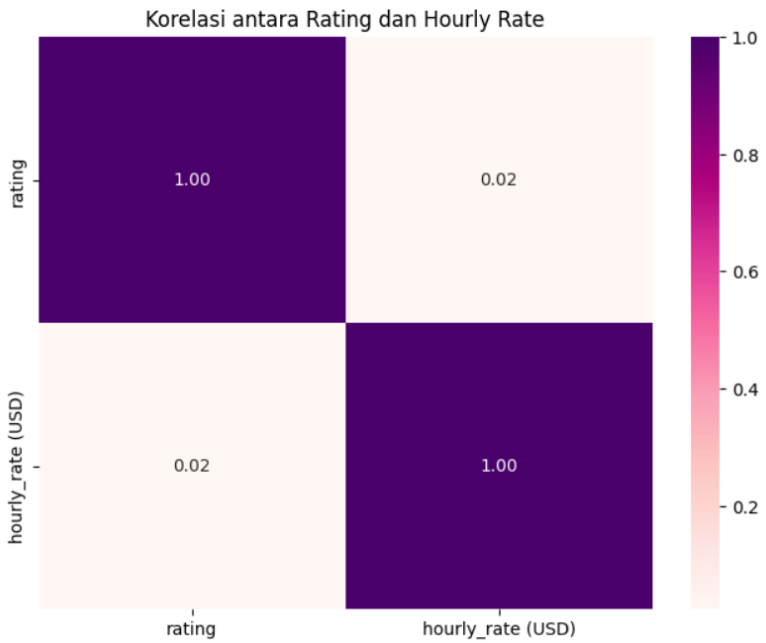

Gambar 2.2.1 4 Output Relationship

Pada gambar 2.2.1.4 dapat terlihat bahwa hubungan antara penilaian pelanggan dengan tingkat pendapatan per jam *freelancer* sangat kecil, yaitu dengan nilai sebesar

0,002. Artinya, kedua variabel tersebut hampir tidak memiliki hubungan, tinggi rendahnya penilaian pelanggan terhadap *freelancer* tidak memengaruhi besar kecilnya pendapatan per jam *freelancer.* Dengan kata lain, penentuan tarif freelancer kemungkinan lebih dipengaruhi oleh faktor lain, seperti pengalaman kerja, jenis keahlian, lokasi negara, atau strategi penetapan harga masing-masing individu.

BAB III
PENUTUP

3.1 Kesimpulan

Dari hasil analisis yang dilakukan, dapat disimpulkan bahwa dataset *freelancer* menunjukkan kondisi dan karaktersitik yang sangat beragam, namun tidak terdapat data yang terlalu mencolok antar variabel utama. Sehingga persebaran *freelancer* di berbagai negara terbilang relatif merata, tanpa adanya dominasi yang sangat kuat antar kategori tertentu. Dari sisi performa, penilaian pelanggan terhadap *freelancer* cenderung tersebar di seluruh rentang nilai yang menunjukkan beberapa kualitas layanan yang cukup tinggi. Namun, ketika dibandingkan dengan variabel lain seperti jumlah pendapatan per jam *(hourly_rate (USD))*, diketahui bahwa tidak terdapat hubungan yang signifikan antara penilaian pelanggan terhadap *freelancer* dan pendapatan yang didapatkan, sehingga dapat dikatakan bahwa kepuasan pelanggan bukan satu-satunya faktor yang menentukan besarnya penghasilan *freelancer*.

Selain itu, hasil analisis juga menunjukkan bahwa pengalaman kerja memiliki kecenderungan lebih relevan terhadap pendapatan dibandingkan penilaian pelanggan, meskipun pola hubungannya tidak terlalu kuat karena distribusi data yang terbatas. Sementara itu, perbandingan antar keahlian menunjukkan bahwa perbedaan performa penilaian antar keahlian relatif kecil, sehingga jenis keahlian tidak menjadi faktor utama dalam menentukan kualitas layanan. Dengan demikian, dapat disimpulkan bahwa faktor-faktor seperti pengalaman, strategi penetapan harga, dan kemungkinan faktor eksternal lainnya lebih berpengaruh terhadap pendapatan *freelancer* dibandingkan hanya penilaian pelanggan atau jenis keahlian dari *freelancer*.